

① الف) بایک Perceptron تابعی که خطی تفکیک پذیراند را ساخت.

حالا n و z را دوی z را خروجی در نظر می گیریم، خطی غیر قابل تفکیک است.

$Z=0$	$Z=\sim n$	$Z=\sim n \wedge y$	$Z=\sim n \vee \sim y$
$Z=1$	$Z=\sim y$	$Z=\sim n \wedge \sim y$	$Z=\sim n \vee y$
$Z=\sim n$	$Z=n \wedge y$	$Z=n \vee y$	
$Z=y$	$Z=n \wedge \sim y$	$Z=n \vee \sim y$	

← از بین ~~۱۴~~ تا فقط ۱۴ تار آضا قابل ساخت اند. به عبارتی $n \oplus y$ و $n \oplus \sim y$ را نمی توانیم با Perceptron تفکیک کنیم زیرا خطی تفکیک پذیر نیست.

ب) خیر، مشکل نباید شدن نگرانیان باطل این است که مستقی این تابع در مقادیر خیلی زیاد یا خیلی کمتر صفر می شود که ربطی به صفر محور بودن ندارد ← هر دو مشکل نباید شدن نگرانیان را دارند.

ج) طبق قضیه Universal approximation می دانیم که بایک شبکه عصبی فقط یک لایر پنهان دارد تابع activation آن غیر خطی است. هر تابع پیوسته در یک مجموعه ای finite را می توان تقریب زد.

د) خیر ممکن است در صورت کم بودن دیتار train باعث پیچیده شدن بیش از حد مدل شویم و مشکلی مثل overfitting اتفاق بیفتد! حتی مشکلی مثل نباید شدن نگرانیان بیش از حد آید.

ه) طبق همان قضیه Universal approximation می دانیم که با تشکیل یک شبکه $wide$ و تعداد زیادی لایر درون تقریباً هر تابعی را می توان ساخت و تقریب زد. ولی در شبکه های عمیق با تعداد لایر کمتر می توانیم همان کار را انجام دهیم.

و) نباید شدن نگرانیان عبارت است از وقتی که نگرانیان ما نسبت به پارامترها خیلی کوچک است و باعث می شود آپدیت ما خیلی کم انجام شود و عملاً آپدیتی نداشته باشیم. تابعی مثل ReLU، مشتق آن همواره ۱ است و ~~محاسبه~~ تقریبی نمی کند و کوچک نمی شود و باعث ایجاد پیچیدگی نباید شدن نگرانیان نمی شود.

(۴) درست است در SGD چون نسبت به هر سیمبل آبدیت می‌کنیم ← فرکانس بالای ورود و خروج می‌کند
ولی ممکن است تدریس مینییم می‌شود می‌تواند، مقدار converge کردن

(۵)

$$\frac{\partial \mathcal{L}}{\partial w} = 1.2w^3 - 0.3w^2 - 4w - 0.1 \quad \xrightarrow{w_0 = -2.18} \quad \underbrace{-11.2944}_{g_1} \quad m_0 \text{ را صفر در نظر می‌گیریم}$$

$$\begin{cases} m_{t+1} = \mu m_t + (1-\mu) \nabla_w \mathcal{L}(w) \\ x_{t+1} = x_t - \gamma m_{t+1} \end{cases}$$

$$m_1 = 0.1 \times 0 + 0.9 \times (-11.2944) = -10.16496$$

$$w_1 = -2.18 - (0.05) (-10.16496) = -2.068752$$

$$m_2 = 0.1 (-10.16496) + 0.9 (g_2) \approx -7.4247$$

$$g_2 = (1.2w^3 - 0.3w^2 - 4w - 0.1) \xrightarrow{w = -2.068752} \approx -11.94278$$

$$w_2 = -2.068752 - (0.05) (-7.4247) = -2.027515$$

۲- ابتدا تابعی که ~~ماکزیمم~~ ^{الفا} ~~ماکزیمم~~ بین دو عدد را خروجی می‌دهد را می‌کنیم، با استفاده از ReLU، داریم که اگر $a_1 > a_2$ $ReLU(a_1 - a_2) = a_1 - a_2$ ← وگرنه خروجی صفر است ←


$$ReLU(a_1 - a_2) + a_2 = \max\{a_1, a_2\}$$

$$\text{if } a_1 > a_2 \rightarrow a_1 - a_2 + a_2 = a_1$$

$$\text{else} \rightarrow 0 + a_2 = a_2$$

$$\max\{a_1, a_2, a_3\} = \max\{\max\{a_1, a_2\}, a_3\}$$

حالا تکرار می‌کنیم به سبب تعریف




پس این شد شبکه ندرود

ماکزیمم سه ورودی را خروجی می‌دهد.

abs تابع قدر مطلق

اسم این شبکه را $B(x)$ می گذاریم. حالا داریم که ۱

بله بین این سه مورد ماکزیمم بگیریم
سپس باید $\frac{1}{4}$ برابر آنرا به exp کنیم



حالا شبکه را مربوط به z_2 را می سازیم.


$$\begin{cases} \text{if } \sqrt{(x_1+3)^2 + (x_2-5)^2} > 4 \rightarrow 0 \\ \text{else} \rightarrow 1 \end{cases}$$

یعنی اگر $\sqrt{(x_1+3)^2 + (x_2-5)^2} - 4 < 0$ مقدار تابع ۱ است و در غیر اینصورت صفر است.


این step func تعریف می کنیم که اگر مقدار ورودی استی بزرگتر مساوی صفر بود به یک خروجی دهد وگرنه صفر خروجی دهد.

(دقت شود که ورودی ها عدد در این نورون ها اولی

دو ورودی اعمال شوند، سپس عملیات داخل نورون)




حالا داریم که $y = 4z_1 + 2z_2 + 4$




(ب) توان رانی توان بنویسیم و آنرا باید به صورت جمع در بیاوریم پس \log بگیریم تا توان تبدیل به ضرب شود و دوباره \log بگیریم ضرب به جمع تبدیل شود.

$$x_1^{x_2} \xrightarrow{\log} x_2 \log x_1 \xrightarrow{\log} \log x_2 + \log \log x_1$$

$$\Rightarrow x_1^{x_2} = e^{(\log x_2 + \log \log x_1)}$$



حالا ما تبدیل قبل \max را با استفاده از ReLU می سازیم.



۳- بعد درونی عبارت است $D_{x \times x}$ ، بعد z_1 ، $D_{a_1 \times x_1}$ است.

پس داریم که:

۱- بعد w_1 عبارت است از $D_{a_1 \times x_1} \times D_{x \times x_1}$ همچنین بعد b_1 برابر است با بعد z_1 و $D_{a_1 \times x_1}$.

خروجی هم اسکالر است ← پس بعد b_2 برابر است با 1×1 و بعد w_2 برابر است با $1 \times D_{a_1}$.

اگر بخوایم n تا سیل داشته باشیم، بعد x می شود $D_x \times x^n$.

و بعد a_1 ، z_1 عبارت می شوند از $D_{a_1 \times n}$ ، در نتیجه بعد w_1 تغییر نمی کند.

جمع به ازای هر سیل باید عین قبل خروجی هر ده داریم و تعدادی سیل این ماتریس را ضرب می کنیم و همان نتیجه را می دهد.

وی بعد باید تخصیص داد و باید در n ضرب شود. (n بار تکرار شود) $\leftarrow D_{a_1} \times n$

$$\Rightarrow w_1 : D_{a_1} \times D_x$$

$$w_r : 1 \times D_{a_1}$$

$$x : D_n \times n$$

$$\hat{y} : 1 \times n$$

$$\delta_1^{(i)} = \frac{\partial J}{\partial \hat{y}^{(i)}} = -\frac{1}{m} \left(\frac{\partial L^{(i)}}{\partial \hat{y}^{(i)}} \right) = -\frac{1}{m} \left(\frac{y^{(i)}}{\hat{y}^{(i)}} - \frac{(1-y^{(i)})}{1-\hat{y}^{(i)}} \right) = \frac{1}{m} \left(\frac{(1-y^{(i)})}{1-\hat{y}^{(i)}} - \frac{y^{(i)}}{\hat{y}^{(i)}} \right)$$

$$\frac{\partial J}{\partial \hat{y}} = \left[\frac{\partial J}{\partial \hat{y}^{(1)}}, \dots, \frac{\partial J}{\partial \hat{y}^{(n)}} \right]^T = \begin{bmatrix} \frac{1-y^{(1)}}{1-\hat{y}^{(1)}} - \frac{y^{(1)}}{\hat{y}^{(1)}} \\ \vdots \\ \frac{1-y^{(n)}}{1-\hat{y}^{(n)}} - \frac{y^{(n)}}{\hat{y}^{(n)}} \end{bmatrix}$$

$$\delta_r^{(i)} = \frac{\partial \hat{y}^{(i)}}{\partial z_r} = \frac{\partial \sigma(z_r)}{\partial z_r} = \sigma(z_r)(1-\sigma(z_r)) = \hat{y}^{(i)}(1-y^{(i)})$$

$$\delta_r^{(i)} = \frac{\partial z_r}{\partial a_1} = \frac{\partial (w_r a_1 + b_r)}{\partial a_1} = w_r$$

$$\delta_e^{(i)} = \frac{\partial a_1}{\partial z_1} = \frac{\partial \text{ReLU}(z_1)}{\partial z_1} = \begin{cases} 1 & z_1 > 0 \\ 0 & \text{o.w.} \end{cases}$$

$$\delta_o^{(i)} = \frac{\partial z_1}{\partial w_1} = \frac{\partial (w_1 x^{(i)} + b_1)}{\partial w_1} = x^{(i)T}$$

$$\frac{\partial J}{\partial w_1} = \frac{\partial J}{\partial \hat{y}} \times \frac{\partial \hat{y}}{\partial z_r} \times \frac{\partial z_r}{\partial a_1} \times \frac{\partial a_1}{\partial z_1} \times \frac{\partial z_1}{\partial w_1} = \text{ضرب عبارات بالا هست}$$

۷. بار تکرار

$$Z_1 = W_1 X + b_1 = \begin{bmatrix} a & b \\ -a & a \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} a \\ -a \end{bmatrix} \rightarrow \sigma(Z_1) = \begin{bmatrix} \frac{1}{1+e^{-a}} \\ \frac{1}{1+e^{+a}} \end{bmatrix}$$

$$Z_r = W_r Z_1 + b_r = \begin{bmatrix} a & -b \\ b & -a \end{bmatrix} \begin{bmatrix} \frac{1}{1+e^{-a}} \\ \frac{1}{1+e^{+a}} \end{bmatrix} = \begin{bmatrix} \frac{a}{1+e^{-a}} - \frac{b}{1+e^{+a}} \\ \frac{b}{1+e^{-a}} - \frac{a}{1+e^{+a}} \end{bmatrix} \rightarrow \begin{matrix} \frac{ae^a - b}{1+e^a} \\ \frac{be^a - a}{1+e^a} \end{matrix}$$

$$\text{ReLU}(Z_r) = \begin{bmatrix} \frac{\text{ReLU}(ae^a - b)}{1+e^a} \\ \frac{\text{ReLU}(be^a - a)}{1+e^a} \end{bmatrix}$$

$$Z_r = W_r Z_r + b_r = \begin{bmatrix} a & -a \\ -b & b \end{bmatrix} \begin{bmatrix} \frac{\text{ReLU}(ae^a - b)}{1+e^a} \\ \frac{\text{ReLU}(be^a - a)}{1+e^a} \end{bmatrix} = \begin{matrix} \frac{a \text{ReLU}(ae^a - b) - a \text{ReLU}(be^a - a)}{1+e^a} \\ \frac{-b \text{ReLU}(ae^a - b) + b \text{ReLU}(be^a - a)}{1+e^a} \end{matrix}$$

$$\begin{bmatrix} \frac{a \text{ReLU}(ae^a - b) - a \text{ReLU}(be^a - a)}{1+e^a} \\ \frac{-b \text{ReLU}(ae^a - b) + b \text{ReLU}(be^a - a)}{1+e^a} \end{bmatrix} \rightarrow \begin{matrix} s_1 \\ s_r \end{matrix}$$

$$\rightarrow \text{softmax}(Z_r) = \begin{bmatrix} \frac{\exp(s_1)}{\exp(s_1) + \exp(s_r)} \\ \frac{\exp(s_r)}{\exp(s_1) + \exp(s_r)} \end{bmatrix}$$

$$\begin{matrix} \sigma^z \\ \text{output} \\ \downarrow \end{matrix} Z_r = \begin{bmatrix} a & 1/a \\ -b & a \end{bmatrix} \begin{bmatrix} \frac{e^{s_1}}{e^{s_1} + e^{s_r}} \\ \frac{e^{s_r}}{e^{s_1} + e^{s_r}} \end{bmatrix} = \begin{bmatrix} \frac{ae^{s_1} + 1/a e^{s_r}}{e^{s_1} + e^{s_r}} \\ \frac{-be^{s_1} + ae^{s_r}}{e^{s_1} + e^{s_r}} \end{bmatrix} \rightarrow \begin{matrix} y_1 \\ y_r \end{matrix}$$

$$a_f = \begin{bmatrix} y_1 \\ y_r \end{bmatrix}$$

$$E = \frac{1}{r} \left((y_1 - t_1)^r + (y_r - t_r)^r \right) = \frac{1}{r} \left((y_1 - 0)^r + (y_r - 1)^r \right) = \quad (b)$$

$$\frac{1}{r} \left(\frac{ae^{s_1} + ae^{s_r}}{e^{s_1} + e^{s_r}} \right)^r + \frac{1}{r} \left(\frac{-be^{s_1} + ae^{s_r}}{e^{s_1} + e^{s_r}} - 1 \right)^r$$

(c)

$$\frac{\partial E}{\partial a_r} = a_r - t \quad \frac{\partial E}{\partial a_r} = \frac{\partial E}{\partial a_r} \frac{\partial a_r}{\partial a_r} = w_r^T (a_r - t)$$

$$\frac{\partial E}{\partial w_r} = \frac{\partial E}{\partial a_r} \frac{\partial a_r}{\partial w_r} = (a_r - t) a_r^T$$

$$\frac{\partial E}{\partial b_r} = \frac{\partial E}{\partial a_r} \frac{\partial a_r}{\partial b_r} = (a_r - t) \times 1 = (a_r - t)$$

$$\frac{\partial E}{\partial z_r} = \frac{\partial E}{\partial a_r} \frac{\partial a_r}{\partial z_r} = (\text{diag}(a_r) - a_r a_r^T) w_r^T (a_r - t)$$

$$\frac{\partial E}{\partial w_r} = \frac{\partial E}{\partial z_r} \frac{\partial z_r}{\partial w_r} = (\text{diag}(a_r) - a_r a_r^T) w_r^T (a_r - t) a_r$$

$$\frac{\partial E}{\partial b_r} = \frac{\partial E}{\partial z_r} \frac{\partial z_r}{\partial b_r} = (\text{diag}(a_r) - a_r a_r^T) w_r^T (a_r - t)$$

$$\frac{\partial E}{\partial a_r} = \frac{\partial E}{\partial z_r} \frac{\partial z_r}{\partial a_r} = \frac{\partial E}{\partial z_r} \frac{\partial z_r}{\partial a_r} w_r^T (\text{diag}(a_r) - a_r a_r^T) w_r^T (a_r - t)$$

اسمى را ماتریس ۱ میزنیم

$$\frac{\partial E}{\partial z_r} = \frac{\partial E}{\partial a_r} \frac{\partial a_r}{\partial z_r} = \left[\begin{array}{c} \text{ } \end{array} \right] w_r^T (\text{diag}(a_r) - a_r a_r^T) w_r^T (a_r - t)$$

بسته به اینکه مشتق یا عبارات \rightarrow مشتق $Rel(z)$ به z_r که هر حایه می تواند یا ۱ باشد

$$\frac{\partial E}{\partial w_r} = \frac{\partial E}{\partial z_r} \frac{\partial z_r}{\partial w_r} = A w_r^T (\text{diag}(a_r) - a_r a_r^T) w_e^T (a_e - t)$$

$$\frac{\partial E}{\partial b_r} = \frac{\partial E}{\partial z_r} \frac{\partial z_r}{\partial b_r} = A w_r^T (\text{diag}(a_r) - a_r a_r^T) w_e^T (a_e - t)$$

$$\frac{\partial E}{\partial a_1} = \frac{\partial E}{\partial z_r} \frac{\partial z_r}{\partial a_1} = w_r^T A w_e^T (\text{diag}(a_r) - a_r a_r^T) w_e^T (a_e - t)$$

$$\frac{\partial E}{\partial z_1} = \frac{\partial E}{\partial a_1} \frac{\partial a_1}{\partial z_1} = \text{diag}(\underbrace{a_1(1-a_1)}_{\text{نیمب-المنت طیز}}) w_r^T A w_e^T (\text{diag}(a_r) - a_r a_r^T) w_e^T (a_e - t)$$

$$\frac{\partial E}{\partial b_1} = \frac{\partial E}{\partial z_1} \frac{\partial z_1}{\partial b_1} = \text{diag}(a_1 \odot (1-a_1)) w_r^T A w_e^T (\text{diag}(a_r) - a_r a_r^T) w_e^T (a_e - t)$$

مقدار وزن ها و بایاس ها را با استفاده از گرادیان کاهشی دنیخ یادگیر η می توانیم
با استفاده از فیکد زیر به دست آوریم:

For key in params.key():

params[key] -= η grads[key]


تمام مقادیر وزن ها و بایاس ها را ~~بمنهای~~ η برابر گرادیان متناظرشان
($\partial E / \partial p$) می کنیم.
پارامتر

الف) ۱۲ خط نیاز است که
۴ تا از آنها مشترک هستند.

← ۱۲ خط نیاز داریم.

برابر کردن هر ۴ تا and نیاز داریم.

در نهایت هر تمام ۴ لونی ها را باید or کنیم.



① $\begin{cases} y+n \leq 1 \\ y+n \geq -1 \\ y-n \leq 5 \\ y-n \geq 3 \end{cases}$


② $\begin{cases} y+n \leq 5 \\ y+n \geq 3 \\ y-n \leq 1 \\ y-n \geq -1 \end{cases}$



③ $\begin{cases} y+n \leq -3 \\ y+n \geq -5 \\ y-n \leq 1 \\ y-n \geq -1 \end{cases}$

④ $\begin{cases} y+n \leq 1 \\ y+n \geq -1 \\ y-n \leq -3 \\ y-n \geq -5 \end{cases}$

① و ④ با هم اشتراک دارند ② و ③ هر با هم اشتراک دارند، حالا جدا جدا می‌کنیم برابر هم بکنیم.

تابع step func هر در سوال قبل تعریف کردیم،
$$f(x) = \begin{cases} 1 & x \geq 0 \\ 0 & o.w. \end{cases}$$





● or نودهای خروجی ها

← در کل به ۱۷ نودون نیاز داریم

ب) این نودون به ۸ حفره نیاز دارد و ● و ● and و ما در مدل قبلی بیش از این تعداد نودون دراییم بنابراین با تخصیص وزن ها ● می توان این مدل را نیز شبیه سازی کرد

خروجی ها را به ترتیب O_1 O_2 O_3 O_4 O_5

نامگذاری می کنیم، خواصی دارند است.

A: O_5 به نودون دایره و ~~نقطه~~ فقط یک خط می تواند بسازد $\leftarrow O_5$

B: O_1 و O_2 دوتا خط است و قابل سخت با O_3 است. (به نودون برابر هر خط و یکی برابر است)

C: ~~برابر~~ برابر سخت O_4 مناسب است زیرا x_{or} دوتا ~~نقطه~~ ~~نقطه~~ است دوتا نودون برابر سخت

D: ~~برابر~~ برابر سخت O_2 مناسب است، به خط عمودی O_3 به نودون که فقط به x_1 وابسته است

E: برابر سخت O_2 مناسب است، زیرا x_2 وابسته است می خواهد. P مناسب است. یکی برابر x_1 خط ها یکم برابر خروجی.

F: برابر سخت O_4 مناسب است. دوتا خط عمودی و افقی \leftarrow درودی نودون ها

x_1 و x_2 یک خط اریب \leftarrow درودی است x_1 و x_2 یک نودون هر برابر خروجی \leftarrow

F برابر سخت O_4 مناسب است.

۶. می دانیم که داریم

$$z^{(L+1)} = w^{(L)} h^{(L)} + b^{(L)}$$

$$h^{(L+1)} = \text{ReLU}(z^{(L+1)})$$

حالا اگر $z_i^{[L]} \geq 0$ خروجی ReLU برابر خود عبارت است. عبارت 1x
 اگر $z_i^{[L]} < 0$ خروجی ReLU برابر صفر است. عبارت 0x

پس بردار $c^{[L]}$ را تعریف می کنیم برابر لایه دانه در $z^{[L]}$ ضرب الممنت و این می کنیم

$$\begin{aligned} c_i^{[L]} &= 1 \quad \text{iff} \quad z_i^{[L]} \geq 0 \\ c_i^{[L]} &= 0 \quad \text{iff} \quad z_i^{[L]} < 0 \end{aligned} \rightarrow h^{[L]} = c^{[L]} \odot z^{[L]}$$

حالا این را در معادله بالاتر جایگذاری می کنیم، خواهیم داشت:

$$z^{[L+1]} = w^{[L]} h^{[L]} + b^{[L]} = w^{[L]} (c^{[L]} \odot z^{[L]}) + b^{[L]}$$

می توانیم آن درایه ای که $c^{[L]}$ ، آنرا در $z^{[L]}$ ضرب می کنیم استقاده متناظرش در $w^{[L]}$ را ضرب می کنیم
 و به عبارتی $\hat{w}^{[L]}$ بجای $w^{[L]}$ استفاده می کنیم به صورت
 (هر سطر $w^{[L]}$ را ضرب الممنت و این در c می کنیم تا \hat{w} حاصل شود.)

$$\rightarrow \hat{w}^{[L]} z^{[L]} + b^{[L]}$$

$$\rightarrow z^{[L+1]} = \hat{w}^{[L]} \left(\hat{w}^{[L-1]} (\dots) + b^{[L-1]} \right) + b^{[L]} =$$

$$\left(\prod_{k=1}^L \hat{w}^{[k]} \right) z^{[1]} + \sum_{k=1}^L \left(\prod_{k=k+1}^L \hat{w}^{[k]} \right) b^{[k]}$$

$$z^{[1]} = w^{[0]} x + b^{[0]} \quad \text{از طرفی}$$

پس داریم که:

$$\underbrace{\left(\prod_{k=0}^L \hat{w}^{[k]} \right)}_{\tilde{w}^{[L]} \text{ می نامیم}} \eta + \sum_{i=0}^L \underbrace{\left(\prod_{k=i+1}^L \hat{w}^{[k]} \right)}_{\tilde{b}^{[i]} \text{ می نامیم}} b^{[i]}$$

حالا $\tilde{w}^{[L]}$ و $\tilde{b}^{[i]}$ متغیرهای ثابتی هستند به صورت یکتا توسط activation function

ها تعیین می شوند، پس داریم که:

$$\left(\prod_{k=0}^{L+1} \right) \circ (\tilde{w}^{[L]} \eta + \tilde{b}^{[L]}) \geq 0$$

ب) اگر $m > k$:

$$r(k, m) \leq \sum_{i=0}^k \binom{k}{i} = 2^k \leq k^k \leq k^m$$

اگر $m \leq k$:

$$r(k, m) \leq \sum_{i=0}^m \binom{k}{i} \left(\frac{k}{m} \right)^{m-i} \leq \sum_{i=0}^k \binom{k}{i} \left(\frac{k}{m} \right)^{m-i} = \left(\frac{k}{m} \right)^m \sum_{i=0}^k \binom{k}{i} \left(\frac{k}{m} \right)^{-i}$$

$$1 - m \leq e^{-m}$$

$$= \left(\frac{k}{m} \right)^m \sum_{i=0}^k \binom{k}{i} \left(\frac{m}{k} \right)^i = \left(\frac{k}{m} \right)^m \left(1 + \frac{m}{k} \right)^k \leq \left(\frac{e}{m} \right)^m k^m \leq O(k^m)$$

از عبارت اول هر دایمیر هر لایه یک پلی توپ تشکیل می دهد.

حالا هر لایه نهایتاً $O(k^m)$ تا خط (نماده می کنه) در نتیجه:

$$\textcircled{1} \rightarrow O(k^m) \quad \textcircled{2} \rightarrow O(k^{nm})$$

در نهایت برابر n تا $O(k^{nm})$ است.